

PROTOCOLO DE GÊMEO DIGITAL AUTÔNOMO NO PROCESSO DA MISTURA DE ALGODÃO NA FIAÇÃO TÊXTIL COM APRENDIZADO POR REFORÇO E SIMULAÇÃO DE EVENTOS DISCRETOS

Felipe Papa Capalbo (Universidade Federal de São Carlos – UFSCar)
Victor C. B. Camargo (Universidade Federal de São Carlos – UFSCar)



A melhoria do processo de mistura de algodão na fiação têxtil envolve desafios, em grande parte devido à variabilidade nas propriedades físicas e químicas da fibra de algodão, assim como nas condições operacionais do processo. Esses fatores, influenciados por aspectos ambientais e logísticos, tornam o planejamento dos fardos adequados uma tarefa complexa, especialmente em cenários incertos. Historicamente, métodos de programação matemática são empregados para abordar essas questões; entretanto, a introdução do Aprendizado por Reforço, aliado à Simulação de Eventos Discretos, oferece novas possibilidades para a proposição de soluções em ambientes dinâmicos e estocásticos, além de viabilizar a integração de dados físicos em tempo real.

O objetivo deste artigo é apresentar um protocolo de Gêmeo Digital Autônomo, integrando Aprendizado por Reforço, Simulação de Eventos Discretos e outras ferramentas de conectividade, para encontrar boas soluções para a mistura de algodão, considerando incertezas e variabilidades do processo produtivo real. A solução proposta permite lidar com múltiplas fontes de incerteza, incluindo a variabilidade nas propriedades do algodão, como grau de “amarelamento” (+b), refletância total (rd) e Micronaire – que impactam diretamente na qualidade do fio e no custo da produção – e também aspectos logísticos externos, como a procedência desconhecida dos fardos de algodão entregues ao longo do tempo.

Palavras-chave: Gêmeo Digital Autônomo, Aprendizado por Reforço, Simulação de Eventos Discretos, Fiação Têxtil, Mistura de Algodão, Proximal Policy Optimization, Programação Inteira Mista.

1. Introdução

A produção de fios de algodão exige a mistura de fardos com propriedades físico-químicas ($+b$, rd e *Micronaire*) variáveis segundo procedência, clima e armazenamento. A expansão da oferta brasileira, hoje líder global, ampliou essa variabilidade [USDA \(2024\)](#). Simultaneamente, pressões por menores custos, padronização e redução de desperdício tornam as decisões de mistura mais complexas.

Modelos de Programação Matemática, tradicionalmente utilizados [Greene et al. \(1965\)](#), assumem estoques fixos e dados determinísticos, oferecendo suporte limitado em ambientes com entradas contínuas e perturbações estocásticas ([TAKAHASHI, 2016](#)). A demanda por integração de sensores e simulação reforça essa limitação.

Este artigo propõe um protocolo de Gêmeo Digital Autônomo que integra: (i) um Sistema de Informações Gerenciais em *PostgreSQL/Flask* para registrar o estoque; (ii) modelagem do fluxo produtivo em *FlexSim* com variações probabilísticas; e (iii) tomada de decisão em tempo real via Aprendizado por Reforço (*Proximal Policy Optimization* - PPO). A comunicação com o ambiente físico é realizada por *MODBUS*, possibilitando retroalimentação contínua.

O objetivo é conceber e demonstrar a viabilidade de um protocolo que ajuste a mistura em tempo real, mantendo a qualidade do fio frente às variabilidades de suprimento e operação.

2. Revisão de Literatura

Esta seção apresenta a base teórica do artigo. Primeiramente, descreve as propriedades do algodão como matéria-prima e sua relevância para o processo de fiação. Em seguida, introduz os conceitos de Aprendizado por Reforço e Simulação de Eventos Discretos. Por fim, discute a definição de Gêmeo Digital Autônomo e os requisitos de integração entre os sistemas de informação e o ambiente de simulação.

2.1. Processo de fiação na Indústria Têxtil

O algodão apresenta propriedades que impactam o desempenho da fiação e a qualidade do fio, como *Micronaire* (finura e maturidade), comprimento, resistência e tonalidade de cor ([WATERS; PHILLIPS, 1961](#); [DELHOM; KELLY; MARTIN, 2018](#)).

O teste *Micronaire* mede a permeabilidade ao ar e reflete a interação entre finura e maturidade ([LORD, 1956](#)). Fibras finas e maduras favorecem a fiação, enquanto fibras imaturas aumentam a irregularidade. Valores elevados indicam fibras grossas, que melhoram a resistência, mas reduzem a uniformidade ([JR, 2005](#)).

A mistura de algodões é essencial para equilibrar custo e qualidade, reduzindo incertezas (TAKAHASHI, 2016). Greene et al. (1965) introduziram um modelo de programação linear que integra preço, propriedades das fibras e disponibilidade, aproveitando o comportamento linear das características (WATERS; PHILLIPS, 1961).

Segundo Mogahzy (1992), a programação linear também permite adaptação a mudanças de mercado, reduzindo custos e assegurando a previsibilidade da qualidade do fio.

2.2. Aprendizado por Reforço

O Aprendizado por Reforço (AR) é um paradigma de aprendizado baseado em tentativa e erro, no qual um agente interage com o ambiente para maximizar recompensas ao longo do tempo. Diferentemente do aprendizado supervisionado, o AR ajusta ações com base no sinal de recompensa recebido (SUTTON; BARTO, 2014).

Os conceitos fundamentais do AR são:

- Agente: entidade que toma decisões observando o estado do ambiente (s_t), executando uma ação (a_t) e recebendo uma recompensa (r_{t+1}).
- Ambiente: sistema que informa o estado atual e fornece a recompensa baseada na ação do agente.
- Ação: decisão tomada pelo agente para maximizar o retorno acumulado.
- Recompensa: *feedback* numérico que avalia a ação tomada, direcionando o aprendizado.
- Política (π): estratégia que mapeia estados para ações, ajustada com base nas experiências acumuladas.
- Função de valor: estima o benefício esperado de estados ou ações, orientando a melhoria da política.
- Episódio: sequência de interações agente-ambiente, encerrada ao atingir uma condição de término, usada para ajustar a política.

O AR fundamenta-se no *trial-and-error search* e no conceito de recompensa atrasada (SUTTON; BARTO, 2014), exigindo o equilíbrio entre exploração e exploração.

A estabilidade do treinamento e a eficiência no uso de amostras são fatores críticos para a aplicação do AR em sistemas produtivos. O algoritmo PPO estabiliza o treinamento (SCHULMAN et al., 2017), enquanto DQN e DDQN aumentam a eficiência ao reutilizar experiências e reduzir superestimações (HASSELT; GUEZ; SILVER, 2015).

2.2.1 *Proximal Policy Optimization*

O *Proximal Policy Optimization* (PPO) (SCHULMAN et al., 2017) é um algoritmo de AR baseado em gradiente de política, projetado para equilibrar complexidade computacional, estabilidade de treinamento e eficiência na utilização de amostras. Derivado do *Trust Region Policy Optimization* (TRPO), o PPO restringe a magnitude das atualizações da política, evitando oscilações abruptas e promovendo aprendizado consistente.

2.3. Simulação de Eventos Discretos

A Simulação de Eventos Discretos (SED) modela sistemas onde mudanças de estado ocorrem em momentos específicos, como chegadas de clientes ou conclusão de operações. Ao contrário de sistemas contínuos, as transições na SED são pontuais e permitem avaliar impactos sob diferentes condições.

Segundo Banks (2010), a SED é amplamente usada em manufatura, logística, saúde, telecomunicações e redes, sendo adequada para estruturar ambientes de aprendizado em AR.

O modelo define eventos, entidades, atributos e recursos, e sua análise ocorre por simulações numéricas para identificação de padrões e apoio à decisão.

O *FlexSim* é um *software* orientado a objetos para modelar, visualizar e monitorar processos dinâmicos em 2D, 3D e realidade virtual (NORDGREN, 2003), validando dados estatisticamente. Com o *FlexScript*, baseado em C++, permite a customização de objetos e a integração externa via *sockets*, viabilizando a conexão com ambientes como o *Python*.

2.3.1 Simulação de Eventos Discretos e Aprendizado por Reforço

A integração entre AR e SED permite que agentes aprendam estratégias de controle em ambientes estocásticos, ajustando políticas conforme respostas do sistema (LIM; JEONG, 2023). A SED modela operações produtivas, fornecendo contexto para o treinamento.

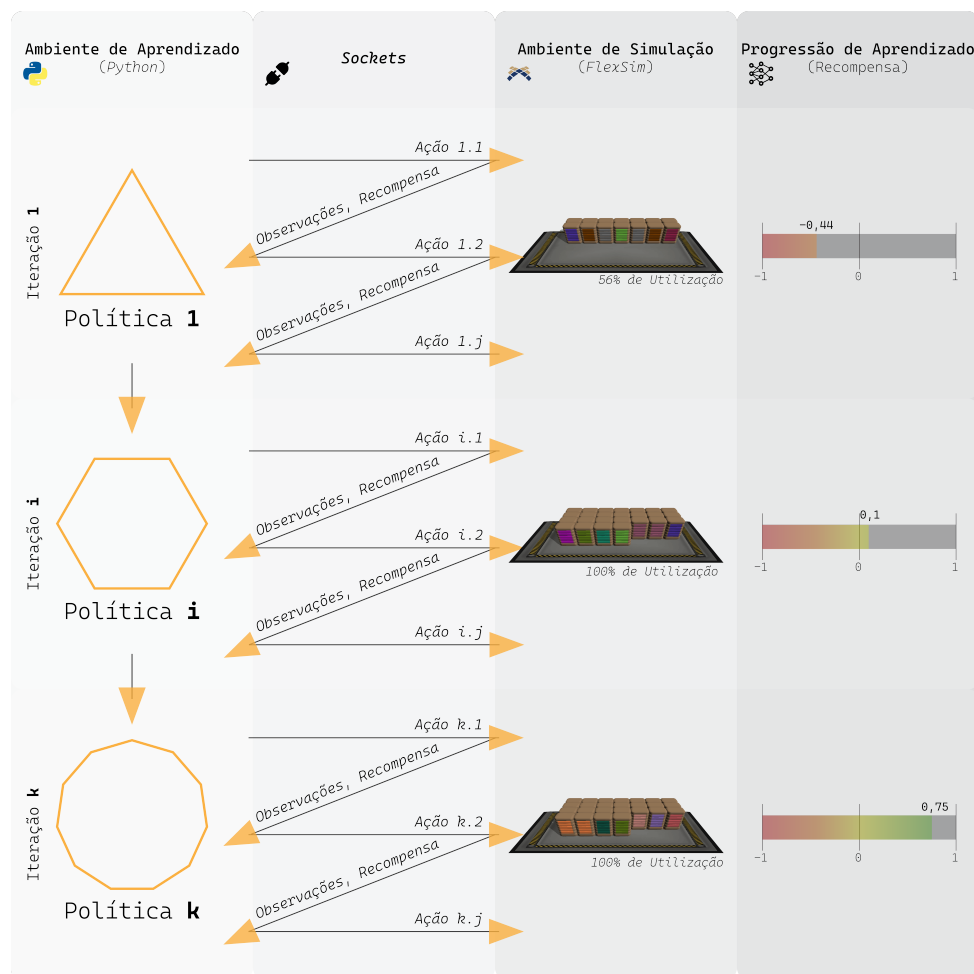
Krenczyk (2024) utilizou um Gêmeo Digital baseado em SED como ambiente de treinamento, aplicando A3C e PPO para alocar processos em linhas paralelas. O agente superou regras tradicionais, melhorando o balanceamento de carga e reduzindo ociosidade, com adaptação a diferentes condições operacionais.

A comunicação entre o simulador e o AR ocorre via *sockets*, transmitindo dados estruturados sobre *TCP/IP*. O agente recebe estados, envia ações e ajusta suas decisões iterativamente.

A separação entre ambiente e algoritmo garante flexibilidade, permitindo ajustes na modelagem e viabilizando a aplicação em cenários onde a experimentação direta é inviável.

A Figura 1 ilustra a estrutura de conexão entre AR e o simulador *FlexSim*.

Figura 1 Representação da estrutura na conexão entre AR e *FlexSim*.



2.4. Gêmeo Digital

O conceito de Gêmeo Digital, proposto por Grieves em 2002 (GRIEVES, 2016), refere-se à criação de uma réplica digital de sistemas físicos para monitoramento, simulação e otimização em tempo real. Inicialmente aplicado em projetos da NASA, expandiu-se para setores como manufatura, energia e infraestrutura urbana.

Segundo Tao et al. (2022), o Gêmeo Digital abrange dimensões geométrica, física, comportamental e de regras, permitindo a representação do objeto e sua resposta a estímulos. Sua eficácia depende do grau de integração com o sistema físico e da capacidade de análise de dados.

Os níveis de maturidade de um Gêmeo Digital refletem o grau de integração entre dados e controle do processo físico (METCALFE et al., 2023; JONES et al., 2020). A evolução é descrita em cinco estágios:

- Nível 0 – *No Twin*: ausência de integração entre medições e o modelo digital.
- Nível 1 – *Status*: coleta de dados em tempo real para visualização do estado atual.
- Nível 2 – Informativo: combinação de dados históricos e atuais para identificar tendências.
- Nível 3 – Preditivo: previsão de comportamento futuro por modelos matemáticos ou aprendizado de máquina.
- Nível 4 – Exploratório: avaliação de cenários para apoiar decisões.
- Nível 5 – Autônomo: execução automática de ações sem intervenção humana.

2.5. Sistema de Informações Gerenciais

A fim de centralizar, automatizar e atualizar as informações dos fardos em estoque e as misturas passadas e futuras, um Sistema de Informações Gerenciais é proposto. Este sistema integra os processos de registro, análise e distribuição das informações.

Sistemas de informações gerenciais representam uma abordagem centrada na arquitetura para o desenvolvimento de sistemas de informações empresariais. Eles incorporam três principais visões: funcional, estrutural e comportamental. A visão funcional descreve o comportamento externo do sistema, enquanto a visão estrutural representa os componentes internos do sistema e suas inter-relações. A visão comportamental captura os aspectos dinâmicos do sistema, demonstrando como os objetos e componentes interagem para realizar os processos de negócios (DENNIS; WIXOM; TEGARDEN, 2009).

2.6. Protocolos de comunicação em Gêmeos Digitais

O protocolo *MODBUS*, por exemplo, é amplamente utilizado em indústrias para facilitar a comunicação entre dispositivos, como Controladores Lógicos Programáveis (CLPs) e sistemas de supervisão. Ele é um protocolo de comunicação serial aberto, desenvolvido em 1979, que se destaca por ser simples de implementar e por ser compatível com diversas mídias de comunicação, como *RS-232*, *RS-485*, *Ethernet* e até mesmo redes sem fio (TAMBOLI et al., 2015).

3. Método de Pesquisa

O artigo fundamenta-se na abordagem de Modelagem e Simulação, amplamente utilizada na Engenharia de Produção e na Gestão de Operações (GANGA, 2011). Essa

metodologia permite analisar, projetar e aprimorar sistemas produtivos, conferindo robustez e flexibilidade à tomada de decisão.

- a) Definição do Problema: propõe-se um método alternativo à programação matemática para a mistura de algodão, adotando o algoritmo PPO pela robustez em ambientes dinâmicos.
- b) Coleta de Dados e Modelo Conceitual: utiliza-se a base de dados de [Takahashi \(2016\)](#), incorporando aleatoriedades no modelo dinâmico.
- c) Construção do Modelo: restrições são representadas na estrutura de recompensas e a simulação replica o processo produtivo.
- d) Solução do Modelo: o PPO resolve o problema iterativamente no ambiente simulado.
- e) Validação do Modelo: compara-se o desempenho do AR às soluções ótimas do modelo matemático.
- f) Implementação da Solução: aplica-se a inferência do modelo treinado para processar dados reais no protocolo de Gêmeo Digital Autônomo.

4. Modelo Matemático

Para validar a abordagem alternativa proposta, adota-se como parâmetro de comparação o modelo matemático de [Takahashi \(2016\)](#), que fornece soluções ótimas para o problema da mistura de algodão. Os dados utilizados, incluindo propriedades dos fardos e valores-alvo das características, são os apresentados no trabalho original.

O modelo selecionado visa a escolha de fardos com base em características não categorizáveis ($+b$, rd e *Micronaire*), buscando minimizar a diferença entre as médias obtidas na mistura e os respectivos valores-alvo. A função objetivo é:

$$\text{Minimizar} \quad \sum_{k=1}^K (\lambda^{+b} A_k + \lambda^{rd} B_k + \lambda^m C_k) Q_k \quad (1)$$

onde A_k , B_k e C_k representam as diferenças absolutas entre a média da mistura e os valores-alvo para cada característica, ponderadas pelos pesos de normalização λ , definidos como o inverso da média das características no estoque. O parâmetro Q_k define o número de vezes que uma determinada mistura k deve ser repetida.

As restrições asseguram a correta formação das misturas e o respeito aos limites de estoque:

$$\sum_{p=1}^P X_{pk} = D_k, \quad \forall k \quad (2)$$

$$\sum_{k=1}^K (X_{pk} Q_k) \leq E_p, \quad \forall p \quad (3)$$

$$X_{pk} \in \mathbb{Z}^+, \quad \forall p, \forall k \quad (4)$$

5. Modelo de Aprendizado por Reforço

Diferentemente da programação matemática, o Aprendizado por Reforço (AR) resolve problemas por tentativa e erro, sem restrições explícitas. A função de recompensa guia o agente, atribuindo *feedback* positivo ou negativo conforme o atendimento às condições do problema. A função objetivo é incorporada à recompensa, favorecendo ações progressivamente melhores.

5.1. Abordagem Estática e Determinística

Inicialmente, o problema é modelado como estático e determinístico: o estoque é fixo e as variáveis conhecidas. Utilizam-se os mesmos dados do modelo matemático.

O objetivo é modelar o problema de maneira diretamente comparável à modelagem original, a fim de encontrar boas extrapolações para cenários incertos.

A formulação base, do ponto de vista do AR, é:

- Ações: seleção das procedências dos 150 fardos no tempo t ;
- Observações: registro das escolhas no tempo $t - 1$;
- Recompensa: inversamente proporcional à função objetivo:

$$R = \frac{1}{1 + \text{FO}} \quad (5)$$

A partir da formulação base, funções de recompensas alternativas foram testadas, a fim de encontrar aquela com a melhor performance:

- **RL I:** Recompensa inversamente proporcional à função objetivo (FO), com penalização fixa para misturas com menos fardos do que o esperado.
- **RL II:** Adição de penalização proporcional aos desvios percentuais das propriedades (rd , $+b$, *Micronaire*) e inclusão da observação da quantidade de estoque por procedência.

- **RL III:** Aumento da penalização para soluções infactíveis de -1 para -2 .
- **RL IV:** Expansão da observação para incluir dois períodos anteriores, $t - 1$ e $t - 2$.
- **RL V:** Penalização extrema (-33) para misturas com quantidade de fardos insuficiente, forçando o agente a respeitar a restrição.
- **RL VI:** Incentivo adicional de $+2$ para soluções onde $FO = 0$, reforçando a busca por soluções ótimas.
- **RL VII:** Alteração da observação do estoque para formato binário (presença ou ausência de fardos).

5.2. Abordagem Dinâmica e Estocástica

No modelo dinâmico, o estoque inicial é aleatório: a quantidade total de fardos é mantida, mas a distribuição por procedência é sorteada. Introduzem-se tempos de processamento e reposição modelados por distribuições *Normais*, ajustados para manter o equilíbrio do sistema:

$$\frac{C}{T_m} = \frac{\mathbb{E}[R]}{T_r} \quad (6)$$

Assumindo que R segue $\mathcal{N}(\mu_R, \sigma^2)$, o tempo médio entre reposições é:

$$\mu_{T_r} = \frac{\mu_R}{C} \cdot \mu_{T_m} \quad (7)$$

A chegada de novos fardos utiliza a distribuição inicial para definir probabilidades de seleção das procedências, respeitando o equilíbrio entre mistura e reposição.

As propriedades *rd*, *+b* e *Micronaire* são aleatorizadas dentro de uma faixa de $\pm 10\%$ dos valores originais:

$$P = P_0 + U(-0.1P_0, 0.1P_0) \quad (8)$$

6. Modelo de Simulação

Para integrar as premissas do ambiente de aprendizado e as ferramentas de conectividade, foi utilizado o simulador de eventos discretos e Gêmeo Digital *FlexSim*. O *FlexSim* permite a representação gráfica tridimensional do processo, aproximando a simulação do contexto real e facilitando a interpretação dos resultados.

O simulador é dividido em duas partes: o *Model 3D*, que representa fisicamente o fluxo de fardos no sistema, e o *Process Flow*, que organiza logicamente os eventos e ações do processo por meio de blocos. O *Model 3D* é utilizado apenas para visualização e lógicas básicas de fluxo, enquanto o *Process Flow* gerencia o comportamento dinâmico dos fardos, a geração de novas chegadas e a integração com os gatilhos de Aprendizado por Reforço (AR).

A Figura 2 ilustra o modelo tridimensional do processo com 34 baias de estoque e um misturador, e o fluxo de eventos construído no *Process Flow* para controle e atualização do ambiente de simulação, na Figura 3.

Figura 2 Representação 3D do processo e do fardo de algodão.


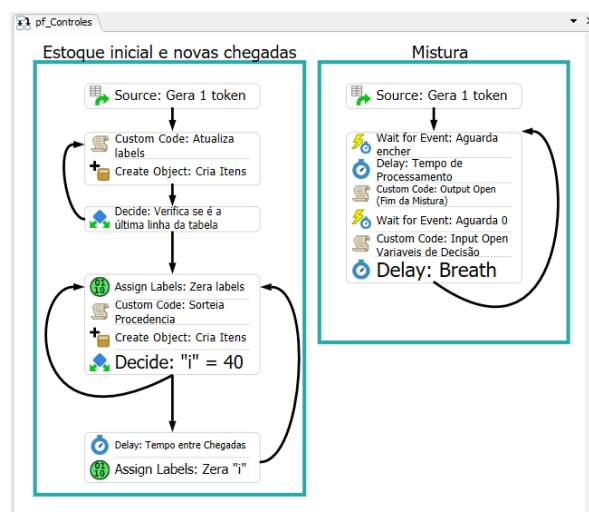


Figura 3 *Process Flow* para gerenciamento do fluxo.



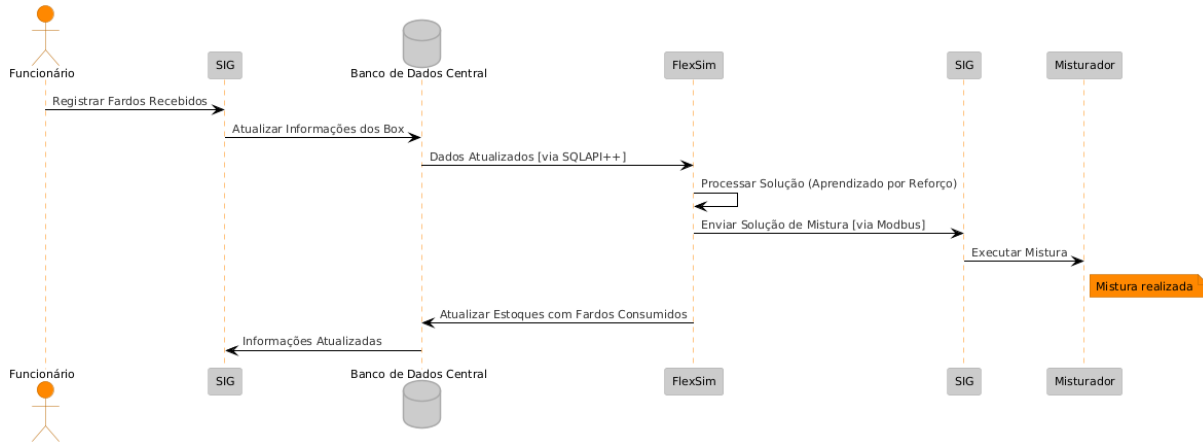
Inicialmente, o *Process Flow* gera os fardos e sorteia suas propriedades, reproduzindo o estoque inicial e controlando as novas chegadas aleatórias ao longo do tempo. Em paralelo, gerencia o direcionamento dos fardos entre as baias de estoque e o misturador, sincronizando as operações e mantendo o ambiente atualizado para a interação com o agente de AR.

7. Sistema de Informações Gerenciais

O Sistema de Informações Gerenciais (SIG) conecta o ambiente físico ao digital no protocolo proposto, substituindo a aleatoriedade da simulação por dados reais por meio do comissionamento virtual, como ilustrado na Figura 4.

Desenvolvido em *Python* com *Flask*, *SQLAlchemy* e *MODBUS*, o SIG gerencia procedências e estoques, consolidando dados em um Banco de Dados *PostgreSQL* (disponível no repositório em anexo). A aplicação web recebe inserções e atualizações de dados. O

Figura 4 Diagrama sequencial do protocolo



servidor *MODBUS*, executado em paralelo, permite a troca de informações entre o SIG (cliente) e o *FlexSim* (servidor).

A sincronização entre o Banco de Dados e o modelo de simulação ocorre via *SQLAPI++*, possibilitando a atualização dos estados do sistema em tempo real. Em paralelo, o agente de Aprendizado por Reforço (AR) toma decisões com base nas informações recebidas do ambiente simulado, continuamente atualizado pelas condições reais do processo.

8. Resultados

As simulações e execuções dos modelos foram realizadas em um sistema com processador i5-11400F, 16 GB de memória RAM e GPU Nvidia GeForce RTX 3060 Ti.

8.1. Abordagem Estática e Determinística

Devido à alta demanda computacional, o problema foi discretizado para viabilizar a aplicação do AR, reduzindo o número de dados sem alterar o comportamento do sistema. A Tabela 1 mostra o impacto da discretização dos modelos de AR no tempo necessário para processar os 18.432.000 *timesteps*.

Tabela 1 Impacto da discretização no tempo computacional.

Discretização (D)	Tempo (horas)
1	646,71
2	345,23
3	156,11
5	97,62
6	62,49

Com o aumento de D , o esforço computacional diminui. A discretização $D = 6$ (25 fardos, ao invés de 150) foi adotada por reduzir o tempo de simulação sem comprometer a qualidade das soluções, conforme mostrado na Figura 5 (compara-se o modelo matemático sem discretização, discretizado e o modelo de AR discretizado).

Figura 5 Comparação entre modelos MIP D1, MIP D6 e RL I.

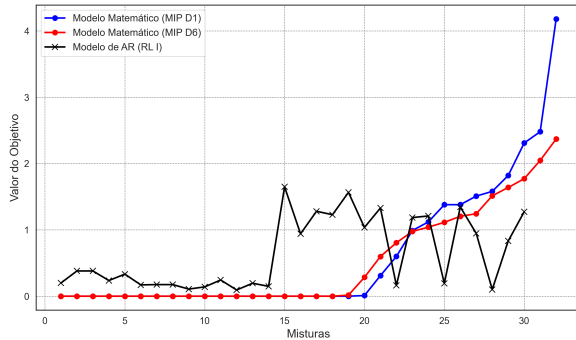
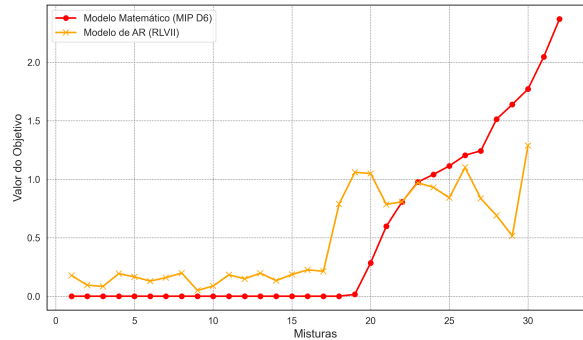


Figura 6 Comparação entre MIP D6 e RL VII.



No ambiente estático, os modelos de Aprendizado por Reforço (RL) convergiram para soluções semelhantes após o treinamento. A Tabela 2 compara o desempenho dos modelos.

Tabela 2 Comparação entre modelos quanto à factibilidade, objetivo e *gap* de otimalidade.

Modelo	Mist. Factíveis	Soma dos Objetivos	<i>Gap</i>
MIP (D6)	33	19,67	-
RL I	30	19,26	57,7%
RL II	29	13,88	32,9%
RL III	30	15,38	25,9%
RL IV	29	15,48	48,2%
RL V	26	17,83	194,8%
RL VI	31	17,33	21,5%
RL VII	30	14,29	17,0%


O MIP apresentou o melhor desempenho como referência. Entre os modelos de RL, o RL VI e o RL VII se destacaram, com *gaps* de 21,5% e 17,0%, respectivamente. O RL VII, com estoque simplificado, obteve a menor variabilidade e maior consistência ao longo das misturas. Enquanto o MIP prioriza o instante atual, o RL distribui melhor os fardos ao longo do tempo, mantendo o desvio mais equilibrado, como mostrado na Figura 6.

8.2. Abordagem Dinâmica e Estocástica

A Figura 7 compara os modelos estático (RL VII) e dinâmico (RL VII DIN). Considerando a chegada contínua de novos fardos, o modelo dinâmico apresenta menor variação

nos valores do objetivo, melhor aderência aos parâmetros desejados e redução da variabilidade e dos picos de erro. Já o modelo estático, operando com estoque fixo, mostra aumento gradual dos desvios à medida que os melhores fardos são consumidos. A média das réplicas do modelo dinâmico foi representada no gráfico.

Figura 7 Comparação entre modelo de AR estático e dinâmico.



9. Conclusão

O artigo propõe um método alternativo para a mistura de algodão na fiação têxtil, desenvolvendo um protocolo de Gêmeo Digital Autônomo que integra dados reais e Aprendizado por Reforço (AR). A abordagem permite ajustes contínuos frente à variabilidade do algodão e das condições operacionais, superando as limitações de métodos determinísticos.

O protocolo atinge o nível 5 de maturidade do Gêmeo Digital, automatizando decisões por meio da integração entre dados operacionais e AR, caracterizando as Dimensões Física e Comportamental. As decisões são continuamente atualizadas a montante e a jusante no processo.

A validação considerou diferentes configurações de simulação e funções de recompensa. O AR apresentou um *gap* de otimalidade de 17% em relação ao modelo matemático, mostrando viabilidade para o planejamento das misturas, apesar de limitações computacionais. Em cenário dinâmico, o AR ajustou progressivamente as decisões conforme novos fardos chegavam, mesmo sem conhecimento prévio exato de suas propriedades.

A integração com o Sistema de Informações Gerenciais e Banco de Dados Relacional viabiliza a atualização automática do ambiente simulado e a transmissão de decisões via protocolo *MODBUS*, permitindo a aplicação prática do protocolo no chão de fábrica.

Referências

BANKS, J. Discrete-Event System Simulation FOURTH EDITION. 2010.

DELHOM, C. D.; KELLY, B.; MARTIN, V. Physical Properties of Cotton Fiber and Their Measurement. In: FANG, D. D. (Ed.). *Cotton Fiber: Physics, Chemistry and Biology*. Cham: Springer International Publishing, 2018. p. 41–73. ISBN 978-3-030-00870-3 978-3-030-00871-0. Disponível em: <http://link.springer.com/10.1007/978-3-030-00871-0_3>.

DENNIS, A.; WIXOM, B. H.; TEGARDEN, D. *Systems analysis and design UML Version 2.0*. [S.l.]: Wiley Hoboken, 2009.

GANGA, G. M. D. *Metodologia Científica e Trabalho de Conclusão de Curso (TCC): um guia prático de conteúdo e forma*. [s.n.], 2011. Disponível em: <<http://livresaber.sead.ufscar.br:8080/jspui/handle/123456789/2780?mode=full>>.

GREENE, J. et al. Linear programming - cotton blending and production allocation. *The Journal of Industrial Engineering*, 1965.

GRIEVES, M. Origins of the digital twin concept. 08 2016.

HASSELT, H. van; GUEZ, A.; SILVER, D. *Deep Reinforcement Learning with Double Q-learning*. 2015. Disponível em: <<https://arxiv.org/abs/1509.06461>>.

JONES, D. et al. Characterising the digital twin: A systematic literature review. *CIRP Journal of Manufacturing Science and Technology*, v. 29, p. 36–52, 2020. ISSN 1755-5817. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S1755581720300110>>.

JR, J. G. M. Relationships between micronaire, fineness, and maturity. i. fundamentals. 2005.

KRENCZYK, D. Deep reinforcement learning and discrete simulation-based digital twin for cyber-physical production systems. *Applied Sciences*, v. 14, n. 12, 2024. ISSN 2076-3417. Disponível em: <<https://www.mdpi.com/2076-3417/14/12/5208>>.

LIM, J.-B.; JEONG, J. Factory simulation of optimization techniques based on deep reinforcement learning for storage devices. *Applied Sciences*, v. 13, n. 17, 2023. ISSN 2076-3417. Disponível em: <<https://www.mdpi.com/2076-3417/13/17/9690>>.

LORD, E. 2—air flow through plugs of textile fibres: part ii. the micronaire test for cotton. *Journal of the Textile Institute Transactions*, Taylor & Francis, v. 47, n. 1, p. T16–T47, 1956.

METCALFE, B. et al. Digital twin maturity levels: a theoretical framework for defining capabilities and goals in the life and environmental sciences. *F1000Research*, v. 12, p. 961, ago. 2023. ISSN 2046-1402. Disponível em: <<https://f1000research.com/articles/12-961/v1>>.

MOGAHZY, Y. E. E. Optimizing cotton blend costs with respect to quality using hvi fiber properties and linear programming: Part i: Fundamentals and advanced techniques of linear programming. *Textile Research Journal*, v. 62, n. 1, p. 1–8, 1992. Disponível em: <<https://doi.org/10.1177/004051759206200101>>.

NORDGREN, W. FlexSim simulation environment. In: *Proceedings of the 2003 International Conference on Machine Learning and Cybernetics (IEEE Cat. No.03EX693)*. New Orleans, LA, USA: IEEE, 2003. p. 197–200. ISBN 978-0-7803-8131-5. Disponível em: <<http://ieeexplore.ieee.org/document/1261424/>>.

SCHULMAN, J. et al. *Proximal Policy Optimization Algorithms*. arXiv, 2017. ArXiv:1707.06347 [cs]. Disponível em: <<http://arxiv.org/abs/1707.06347>>.

SUTTON, R. S.; BARTO, A. G. Reinforcement Learning: An Introduction. 2014.

TAKAHASHI, A. *O problema da mistura na indústria de fiação têxtil*. 2016.

TAMBOLI, S. et al. Implementation of Modbus RTU and Modbus TCP communication using Siemens S7-1200 PLC for batch process. In: *2015 International Conference on Smart Technologies and Management for Computing, Communication, Controls, Energy and Materials (ICSTM)*. Avadi, Chennai, India: IEEE, 2015. p. 258–263. ISBN 978-1-4799-9854-8 978-1-4799-9855-5. Disponível em: <<http://ieeexplore.ieee.org/document/7225424/>>.

TAO, F. et al. Digital twin modeling. *Journal of Manufacturing Systems*, v. 64, p. 372–389, jul. 2022. ISSN 02786125. Disponível em: <<https://linkinghub.elsevier.com/retrieve/pii/S0278612522001108>>.

USDA. *Brazil Passes the United States as Top Cotton Exporter in 2023/24*. 2024. Cotton: World Markets and Trade, United States Department of Agriculture (USDA). Accessed on: 10 November 2024. Disponível em: <<https://downloads.usda.library.cornell.edu/usda-esmis/files/kp78gg36g/j9603s109/3n205r20h/cotton.pdf>>.

WATERS, W. T.; PHILLIPS, J. The Effect of Blending Cottons of Dissimilar Fiber Properties upon Spinning Performance and Yarn Quality. *Textile Research Journal*, v. 31, n. 7, p. 608–618, jul. 1961. ISSN 0040-5175, 1746-7748. Disponível em: <<https://journals.sagepub.com/doi/10.1177/004051756103100705>>.

Anexo

Scripts, arquivos e demais dados relevantes disponíveis no repositório do *GitHub*:

<https://github.com/FelipePCapalbo/TCC>.

Trabalho original disponível em:

<https://felipecapalbo.com/FinalPaper-Bachelor.pdf>